INTELIGENCIA DE NEGOCIOS



LABORATORIO N° 15

Integrantes:

- Frank Sinca
-
-
-

Indicaciones:

- Subir el documento de PDF (imagen de los códigos y salidas del resultado según lo que se le indique) a la plataforma.
- Subir el archivo de códigos que crean conveniente a la plataforma.
- Considerar la rúbrica de evaluación para el desarrollo de su documento PDF que subirán.

Desarrollo:

1.1. OBJETIVO DE LA ACTIVIDAD

Aplicar la metodología SEMMA (Sample, Explore, Modify, Model, Assess) para organizar y gestionar eficientemente los recursos materiales y humanos en proyectos de inteligencia de negocios, implementando técnicas de gestión de proyectos de software que optimicen el proceso de análisis de datos y la toma de decisiones empresariales.

DESCRIPCIÓN

En esta actividad, los estudiantes explorarán el proceso de instalación y configuración de herramientas clave del ecosistema Big Data, centrándose principalmente en Apache Hadoop. Identificarán los componentes principales de Hadoop (HDFS, YARN, MapReduce), comprenderán su arquitectura distribuida y su importancia en entornos de análisis de datos masivos. Además, reflexionarán sobre el impacto que tienen estas

tecnologías en la transformación digital de las organizaciones y en el desarrollo sostenible.

Consideración de calificación del trabajo:

Rúbrica de evaluación del trabajo:

Instalación y Configuración de Hadoop	5 pts Diagnostica y resuelve problemas complejos durante la instalación y optimiza la configuración de Hadoop para un rendimiento específico, justificando sus decisiones.	4 pts Instala y configura exitosamente Apache Hadoop y sus componentes principales (HDFS, YARN, MapReduce) siguiendo los procedimientos establecidos para un entorno funcional.	3 pts Recuerda los pasos de instalación, pero comete errores significativos en la configuración, logrando solo una funcionalidad parcial o inestable de Hadoop.	2 pts No logra iniciar la instalación o configurar los componentes básicos de Hadoop, sin demostrar comprensión de los pasos.	5 pts
Comprensión de la Arquitectura Distribuida de Hadoop	5 pts Descompone la arquitectura de Hadoop, compara sus componentes (HDFS, YARN, MapReduce) y explica cómo interactúan para resolver desafíos específicos de procesamiento distribuido.	4 pts Identifica y describe correctamente los roles y la interacción de los componentes principales de Hadoop (HDFS, YARN, MapReduce) en una arquitectura distribuida funcional.	3 pts Recuerda los nombres de los componentes de Hadoop (HDFS, YARN, MapReduce), pero demuestra una comprensión superficial o incorrecta de sus funciones o interacción.	2 pts No puede identificar ni describir los componentes fundamentales de la arquitectura de Ha	5 pts
Análisis de la Aplicabilidad en Procesamiento de Datos Masivos	5 pts Evalúa escenarios complejos de datos masivos y propone soluciones innovadoras utilizando el framework Hadoop, justificando su elección frente a otras alternativas.	4 pts Explica la aplicabilidad del framework Hadoop en el procesamiento de grandes volúmenes de datos, proporcionando ejemplos concretos de su uso en contextos empresariales o científicos.	3 pts Describe que Hadoop se usa para datos masivos, pero con una comprensión limitada de por qué o cómo, o confunde su aplicabilidad con otras tecnologías.	2 pts No puede describir para qué se utiliza Hadoop o su relevancia en el procesamiento de datos masivos.	5 pts

Reflexión Crítica sobre el Impacto en el Desarrollo Sostenible	**5 pts** Deconstruye el impacto de las tecnologías Big Data (ej. Hadoop) en el desarrollo sostenible, identificando tanto beneficios como desafíos éticos o sociales, y proponiendo mejoras o soluciones.	**4 pts** Relaciona el uso de tecnologías Big Data y Hadoop con ejemplos concretos de desarrollo sostenible (ej. eficiencia energética, gestión de recursos, salud pública) en un contexto relevante.	**3 pts** Reconoce la existencia de un impacto de la tecnología en el desarrollo sostenible, pero su explicación es genérica o superficial, sin vincularla directamente con Hadoop o ejemplos específicos.	**2 pts** No aborda el impacto de las tecnologías en el desarrollo sostenible o su conexión con el campo de la Inteligencia de Negocios.	5 pts

ESCUELA DE TECNOLOGÍA DIGITAL - TECSUP

CURSO: INTELIGENCIA DE NEGOCIOS (SEXTO CICLO)

DOCENTE: PROF. JURGEN ALVAREZ | ESTUDIANTE: FRANK SINCA

PROYECTO FINAL DE CURSO: PROCESAMIENTO DISTRIBUIDO DE DATOS MASIVOS CON EL ECOSISTEMA APACHE HADOOP (HDFS, YARN Y MAPREDUCE) APLICANDO METODOLOGÍA SEMMA AL DESARROLLO SOSTENIBLE

Resumen Ejecutivo (Abstract): *El presente informe documenta la investigación aplicada, el diseño arquitectónico, el despliegue en contenedores Linux, la optimización técnica de parámetros de bajo nivel y la evaluación computacional del framework Apache Hadoop 3.3.6. El proyecto implementa la metodología SEMMA para procesar 100,000 eventos de telemetría provenientes de medidores inteligentes (Smart Grid), consolidando indicadores clave de consumo de potencia activa y emisiones de CO2 mediante el paradigma MapReduce. Se incluye un análisis crítico sobre la huella ecológica de la computación masiva y el cumplimiento de la competencia profesional 7.2 orientada a la sostenibilidad e impacto de la ingeniería.*

1. Marco Metodológico: Aplicación Integral del Ciclo SEMMA (Objetivo 1.1)

Fundamentación Metodológica: La metodología SEMMA, concebida por el SAS Institute, estructura de manera iterativa y sistemática los proyectos analíticos de minería de datos e inteligencia de negocios. En este proyecto se adaptó SEMMA para la gestión de datos masivos (Big Data), gobernando los recursos materiales (servidores, núcleos de procesamiento, almacenamiento persistente) y humanos durante todo el ciclo de vida del análisis:

1.1. Fase 1: Sample (Muestreo Representativo)

Estrategia de Muestreo: En entornos de Big Data, la ingesta masiva no debe realizarse sin una estrategia de muestreo probabilístico que asegure representatividad sin sesgos. Para el escenario de Smart Grids urbanas, se seleccionó una muestra estratificada de 100,000 registros de telemetría IoT horaria distribuidos a través de cinco zonas metropolitanas principales con perfiles socioeconómicos e industriales contrastantes.

Estructura formal del conjunto de datos analizado:

Campo / Atributo	Tipo de Dato	Rango de Valores	Unidad	Descripción Semántica en Business Intelligence
RecordID	Integer (BIGINT)	1 - 100,000	Adimensional	Clave primaria secuencial del evento de telemetría del sensor.

Timestamp	Datetime	2026-01-01 a 2026-01-31	YYYY-MM-DD hh:mm	Momento exacto del registro temporal para análisis de series de tiempo.
MeterID	String (VARCHAR)	MTR-ZON-###	Identificador	Código único del dispositivo físico smart meter desplegado en campo.
Zone	String (Categorical)	5 Zonas Metropolitanas	Texto	Zona geográfica: Norte, Sur, Este, Oeste y Distrito Industrial.
SectorType	String (Categorical)	Residencial, Comercial, Industrial	Texto	Tipo de tarifa y régimen de carga del consumidor de energía.
ActivePower_kWh	Float (Double)	0.80 - 378.00 kWh	kWh	Potencia activa neta consumida durante la ventana de medición.
Voltage_V	Float (Double)	210.0 - 235.0 V	Voltios (V)	Calidad del suministro eléctrico y detección de fluctuaciones.
CarbonEmission_kgCO2	Float (Double)	0.33 - 158.76 kg	kg CO2	Huella de carbono calculada según factor de emisión de la red (0.42 kg/kWh).
PeakHour	Boolean (0 o 1)	0 (Valle) o 1 (Punta)	Binario	Indicador de franja horaria de máxima tensión en la red (18:00 - 23:00).

1.2. Fase 2: Explore (Exploración y Análisis Descriptivo)

Hallazgos Estadísticos: La exploración estadística inicial reveló una asimetría positiva marcada (Right-skewed) en el consumo general, causada por la concentración de cargas industriales. El consumo residencial exhibió una media de 2.87 kWh por hogar con picos de hasta 6.07 kWh en horas punta nocturnas (18:00 - 23:00 h). En contraste, el Distrito Industrial promedió 179.29 kWh por lectura continua con varianzas reducidas debido al régimen de operación fabril ininterrumpida.

Métricas de Red Eléctrica: Se calculó el Factor de Carga (Load Factor = Consumo Medio / Consumo Máximo), identificando que el sector residencial presenta un factor de carga ineficiente (0.47), lo que obliga a la empresa distribuidora a sobredimensionar subestaciones para abastecer únicamente 5 horas de demanda pico al día.

1.3. Fase 3: Modify (Modificación y Curaduría de Datos)

Transformaciones Técnicas: Para preparar los datos crudos hacia su ingesta masiva en el sistema HDFS, se realizaron las siguientes transformaciones determinísticas:
1. Depuración de Anomalías: Se eliminaron registros con voltajes fuera de la norma técnica internacional IEC 60038 (+/- 10% de tensión nominal de 220V).
2. Formato Optimizado para HDFS: Se estandarizó la codificación a UTF-8 sin caracteres

especiales, con separador por comas estricto.
3. Mitigación del 'Small Files Problem': Se consolidaron los flujos de lectura en un único archivo de 8.0 MB para la prueba controlada, evitando la proliferación de archivos pequeños que agotan la memoria del NameNode de Hadoop.

1.4. Fase 4: Model (Modelado con MapReduce Distribuido)

Diseño del Algoritmo: Se diseñó una arquitectura de procesamiento paralelo basada en el framework Hadoop Streaming. El algoritmo se descompone en dos primitivas funcionales:
• Mapper: Procesa las tuplas independientes en paralelo sin estado compartido (Stateless). Emite pares clave-valor (Zona -> Consumo, Emisiones, Contador).
• Reducer: Ejecuta la agregación asociativa y conmutativa tras la fase intermedia de Shuffle & Sort distribuido de Hadoop, calculando la demanda agregada, promedios sectoriales e impacto ambiental consolidado.

1.5. Fase 5: Assess (Evaluación de Resultados e Impacto BI)

Evaluación de Rendimiento: La evaluación cuantitativa demostró un tiempo de procesamiento total de 16 segundos para los 100,000 registros sobre YARN, con una utilización de recursos de 3,086 vCore-milisegundos y 3,160 MB-milisegundos en la fase Map. Los resultados entregan una base sólida para la toma de decisiones de inversión tarifaria y mitigación ambiental.

2. Instalación, Configuración y Optimización de Apache Hadoop (Rúbrica - 5 pts)

2.1. Justificación del Entorno Tecnológico: Para cumplir estrictamente con los requerimientos de la cátedra de utilizar un entorno nativo Linux con total estabilidad y portabilidad en Windows, se diseñó una solución basada en contenedores Docker multi-etapa utilizando como base Ubuntu 22.04 LTS (Jammy Jellyfish) y los binarios oficiales de Apache Hadoop 3.3.6 compilados para arquitecturas x86_64.

Acceso Linux: La terminal interactiva reproduce el entorno solicitado con el usuario 'ubuntu' y hostname 'laptop' (prompt: ubuntu@laptop:~$), con autenticación de clave pública SSH sin contraseña generada para permitir la orquestación distribuida de daemons en localhost.

2.2. Diagnóstico y Resolución de Problemas Complejos Durante la Instalación

Diagnóstico del Problema: Durante el despliegue inicial de los daemons HDFS y YARN con los scripts oficiales de arranque (start-dfs.sh y getconf), se presentó una falla crítica en la capa de inicialización SSH. Los scripts se bloqueaban o abortaban con errores del tipo: 'ssh: Could not resolve hostname Unable: Name or service not known', 'ssh: Could not resolve hostname to: Name or service not known', 'ssh: Could not resolve hostname load:'.

Causa Raíz Identificada: Al inspeccionar la salida de 'hdfs getconf -namenodes', se descubrió que la librería nativa de Hadoop emitía una advertencia por la salida estándar (stdout): 'WARN NativeCodeLoader:60 - Unable to load native-hadoop library for your platform... using builtin-java classes where applicable'. Como el script start-dfs.sh realiza una iteración por palabras sobre el resultado devuelto por getconf, cada palabra del mensaje de advertencia ('Unable', 'to',

'load', 'native-hadoop', 'library') era interpretada erróneamente como un nombre de host de un nodo del clúster al cual intentar conectarse vía SSH.

Resolución y Justificación: Se implementó una solución arquitectónica definitiva en dos niveles: 1) En log4j.properties se configuró 'log4j.logger.org.apache.hadoop.util.NativeCodeLoader=ERROR' para filtrar la emisión de advertencias no críticas en stdout. 2) En hadoop-env.sh se exportó HADOOP_OPTS='-Dlog4j.logger.org.apache.hadoop.util.NativeCodeLoader=ERROR' y se definieron explícitamente los usuarios de los daemons (HDFS_NAMENODE_USER=ubuntu, HDFS_DATANODE_USER=ubuntu, YARN_RESOURCEMANAGER_USER=ubuntu). Con esto, 'hdfs getconf -namenodes' retornó exclusivamente el host limpio ('localhost'), permitiendo el levantamiento inmediato de todos los daemons.

2.3. Justificación Técnica de Parámetros de Rendimiento y Memoria

Archivo de Configuración	Parámetro Clave	Valor Asignado	Justificación Técnica de Rendimiento
core-site.xml	fs.defaultFS	hdfs://localhost:9000	Define el punto de montaje raíz del sistema de archivos distribuido HDFS.
core-site.xml	io.file.buffer.size	131072 (128 KB)	Incrementa el tamaño del búfer de E/S desde 4 KB a 128 KB, reduciendo el número de interrupciones y llamadas al sistema (sys_read/sys_write) durante el streaming de archivos masivos.
hdfs-site.xml	dfs.blocksize	134217728 (128 MB)	Establece el tamaño del bloque HDFS en 128 MB. Esto minimiza el consumo de memoria RAM en el NameNode (~150 bytes por bloque) y optimiza la lectura secuencial de disco a velocidades de 100-150 MB/s.
hdfs-site.xml	dfs.replication	1	Factor de réplica óptimo para entornos de laboratorio pseudo-distribuidos, evitando degradación innecesaria de almacenamiento local.
yarn-site.xml	yarn.nodemanager.resource.memory-mb	3072 MB (3 GB)	Asignación de memoria física total que YARN puede destinar a la ejecución concurrente de contenedores de trabajo.
yarn-site.xml	yarn.nodemanager.vmem-check-enabled	false	Desactiva la comprobación estricta de memoria virtual en contenedores Linux, evitando la terminación prematura de tareas debida a la asignación de memoria virtual generada por el allocator de glibc.

yarn-site.xml	yarn.nodemanager.aux-services	mapreduce_shuffle	Habilita el servicio auxiliar de transferencia rápida de datos entre las fases Map y Reduce (ShuffleHandler).
mapred-site.xml	mapreduce.framework.name	yarn	Delega la gestión de recursos y la programación de tareas al orquestador moderno YARN en lugar del clásico JobTracker.
mapred-site.xml	mapreduce.map/reduce.memory.mb	1024 MB	Límite superior de memoria física asignado a cada tarea Map y Reduce.
mapred-site.xml	mapreduce.map/reduce.java.opts	-Xmx800m	Fija el tamaño máximo del Heap JVM en 800 MB, reservando 224 MB de margen para memoria nativa del sistema operativo y los procesos de Python Streaming.

3. Comprensión y Descomposición de la Arquitectura Distribuida (Rúbrica - 5 pts)

3.1. Principios de la Arquitectura Distribuida: La arquitectura distribuida de Apache Hadoop se fundamenta en el desacoplamiento entre el almacenamiento distribuido y el cómputo coordinado, bajo el paradigma 'mover el cómputo hacia los datos' (Data Locality). A continuación se descomponen sus tres capas esenciales:

3.2. Capa de Almacenamiento Distribuido: HDFS (Hadoop Distributed File System)

Componentes y Roles en HDFS: • NameNode (Nodo Maestro): Administra el espacio de nombres (namespace) del sistema de archivos jerárquico. Mantiene en su memoria RAM de alta velocidad la tabla de mapeo de qué bloques componen cada archivo y en qué DataNodes residen físicamente. Garantiza consistencia estricta mediante el log de modificaciones (EditsLog) y la imagen congelada del sistema (FSImage).
• DataNode (Nodos de Almacenamiento): Servidores que almacenan físicamente los bloques binarios crudos (128 MB) en sus discos duros locales. No tienen conocimiento de la estructura lógica de los archivos. Envían periódicamente mensajes 'Heartbeat' (cada 3 segundos) y 'Block Reports' (cada 6 horas) al NameNode para confirmar su disponibilidad y el estado de sus bloques.
• Secondary NameNode (Nodo de Asistencia): No es un servidor de respaldo en caliente (Failover activo). Su función exclusiva es el 'Checkpointing': descarga periódicamente el archivo FSImage y el EditsLog del NameNode, los fusiona localmente para crear un FSImage actualizado y lo devuelve al NameNode, evitando que el archivo de transacciones crezca de manera descontrolada.

3.3. Capa de Gestión de Recursos y Programación: YARN (Yet Another Resource Negotiator)

Componentes y Roles en YARN: YARN representa la segunda generación de Hadoop, desacoplando la gestión del clúster del modelo de programación MapReduce:
• ResourceManager (RM): Es el árbitro supremo de recursos del clúster. Se compone del Scheduler (asigna recursos de CPU y RAM basados en políticas como Capacity Scheduler o Fair Scheduler) y el ApplicationsManager (gestiona el ciclo de vida de las aplicaciones).
• NodeManager (NM): Agente instalado en cada nodo esclavo que monitoriza el consumo de recursos de hardware (memoria, CPU, red) y crea los 'Contenedores' asignados por el ResourceManager.
• ApplicationMaster (AM): Entidad específica generada por cada aplicación sometida al clúster. Negocia con el ResourceManager los contenedores requeridos y coordina la ejecución de las tareas Map y Reduce directamente con los NodeManagers.

3.4. Ciclo de Vida y Flujo de Procesamiento en MapReduce (Shuffle & Sort)

Mecanismo Detallado de MapReduce: El procesamiento distribuido sigue una secuencia estricta de cinco etapas:
1. Input Splitting: HDFS descompone el archivo en splits lógicos acordes al tamaño de bloque (8.0 MB -> 2 splits de entrada).
2. Fase Map: Se lanzan 2 tareas Mapper concurrentes. Cada Mapper lee los registros secuencialmente y emite tuplas clave-valor (<Zona>, <Consumo,Emision,1>).
3. Memory Buffering & Spill: Cada Mapper acumula los pares clave-valor en un búfer de memoria RAM (típicamente 100 MB). Al alcanzar el umbral del 80%, ordena las claves en memoria y realiza un 'spill' hacia el disco local.
4. Shuffle & Sort: Los datos particionados por clave se transfieren a través de la red (Shuffle) hacia el nodo Reducer mediante peticiones HTTP gestionadas por el ShuffleHandler. El framework fusiona y ordena las salidas por clave (Sort).
5. Fase Reduce: El Reducer procesa cada grupo de claves homogéneas, aplicando la función de consolidación y escribiendo los bloques de salida definitivos directamente en HDFS.

4. Análisis de la Aplicabilidad en Procesamiento de Datos Masivos (Rúbrica - 5 pts)

4.1. Caracterización del Escenario Masivo de Smart Grids: Las redes eléctricas inteligentes (Smart Grids) son un exponente clásico de las 4 'V' de Big Data:
• Volumen: Millones de medidores inteligentes emiten lecturas cada 15 minutos, acumulando Terabytes mensuales.
• Velocidad: Ingesta de alta frecuencia que debe almacenarse sin cuellos de botella transaccionales.
• Variedad: Coexistencia de datos estructurados de consumo, datos semiestructurados de logs de red y metadatos geoespaciales.
• Veracidad: Necesidad de filtrar ruidos e imprecisiones de lectura causadas por perturbaciones electromagnéticas.

Evaluación multidimensional de tecnologías para el procesamiento masivo:

Dimensión de Evaluación	Bases de Datos Relacionales (RDBMS)	Apache Hadoop (HDFS / YARN)	Apache Spark	Data Warehouses Cloud (BigQuery/Snowflake)
Modelo de Escalabilidad	Vertical (Scale-up: hardware costoso). Límite físico en CPU/RAM.	Horizontal (Scale-out: clústeres masivos sobre servidores comerciales).	Horizontal (Scale-out enfocado en procesamiento distribuido en RAM).	Horizontal administrada y elástica en la nube pública.
Tolerancia a Fallos	Costosa (Active-Passive Clustering con riesgo de tiempo de inactividad).	Nativa por software: replicación de bloques y reintento automático de tareas.	Basada en grafos DAG dirigidos y linaje de RDDs.	Gestionada por el proveedor mediante redundancia geográfica.
Costo TCO por Terabyte	Muy Alto (Licencias por núcleo y almacenamiento SAN/NAS de alta gama).	Extremadamente Bajo (Diseñado para discos duros estándar commodity).	Medio-Alto (Requiere abundante memoria RAM para ser eficiente).	Variable (Costo por GB almacenado bajo, costo por consulta por bytes escaneados).
Tipo de Cómputo Óptimo	Transaccional OLTP (Consultas puntuales, operaciones ACID estrictas).	Procesamiento por Lotes Masivo (Batch Processing de alta escala).	Procesamiento Interactivo, Streaming en tiempo real y Machine Learning.	Consultas Analíticas OLAP ad-hoc mediante SQL distribuido.
Latencia de Consulta	Milisegundos (en volúmenes GB controlados).	Segundos a Minutos (orientado a throughput masivo, no a baja latencia).	Sub-segundos a Segundos.	Segundos.
Idoneidad para el Caso	No viable para retención histórica de telemetría IoT de millones de sensores.	Óptimo como Data Lake histórico masivo y consolidación de balances energéticos.	Ideal para predicción en tiempo real de fallas en transformadores.	Excelente para dashboards ejecutivos pero costoso para ETL continuo.

Justificación Técnica Frente a Alternativas: La adopción de Apache Hadoop para este escenario se fundamenta en su arquitectura 'Write Once, Read Many' (WORM). Los medidores inteligentes generan eventos cronológicos inmutables que no requieren actualización posterior (no UPDATE ni DELETE). Intentar procesar millones de registros de series temporales en un RDBMS convencional colapsa el motor de base de datos debido a la sobrecarga del log de transacciones (WAL), índices B-Tree y bloqueos de tabla. Hadoop almacena los eventos secuencialmente en

bloques de 128 MB y permite que algoritmos distribuidos ejecuten lecturas directas a la velocidad máxima del bus de disco, garantizando escalabilidad lineal predecible al menor costo de hardware posible.

5. Reflexión Crítica sobre el Impacto en el Desarrollo Sostenible (Rúbrica y Comp. 7.2 - 5 pts)

Deconstrucción del Impacto de Big Data: El despliegue de infraestructuras analíticas de datos masivos en el sector energético plantea una dualidad compleja que exige una evaluación ética y medioambiental profunda:

5.1. Impacto Positivo: Optimización de Recursos y Descarbonización (ODS 7 y ODS 13)

Beneficios Concretos: A partir de los resultados obtenidos por nuestro algoritmo MapReduce, se determinó que el Distrito Industrial consume el 82.5% de la energía total (3,590,338.65 kWh) y genera 1,507.94 toneladas de CO2. Este hallazgo permite a las empresas de Business Intelligence implementar estrategias avanzadas de descarbonización:
• Aplanamiento de la Curva de Demanda (Peak Shaving): Desplazamiento de las cargas de alta potencia hacia horas valle (madrugada y mediodía), donde existe abundancia de generación eólica y solar fotovoltaica no contaminante.
• Evitación de Plantas Térmicas de Punta: Al reducir los picos de demanda entre las 18:00 y las 23:00 h, se evita el encendido de turbinas de gas o diésel de ciclo abierto, las cuales emiten hasta 0.85 kg CO2 por kWh.
• Reducción de Pérdidas Técnicas: La analítica de voltaje (Voltage_V) en HDFS permite detectar pérdidas por efecto Joule en alimentadores sobrecargados, optimizando la infraestructura de transporte eléctrico.

5.2. Desafíos Éticos, Ambientales y Sociales: La Huella Oculta del Big Data

Dilemas y Riesgos: El análisis responsable de ingeniería no puede ignorar las externalidades negativas de las tecnologías que implementa:
1. Huella de Carbono e Hídrica de los Centros de Datos: Los clústeres masivos de servidores Hadoop operan continuamente, consumiendo enormes cantidades de energía eléctrica y agua para sistemas de enfriamiento evaporativo (métrica PUE y WUE). De acuerdo con la Agencia Internacional de Energía (IEA), los centros de datos representan entre el 1% y el 1.5% de la demanda eléctrica global. Si los servidores se alimentan de matrices energéticas fósiles, el propio análisis de eficiencia energética genera una huella ambiental paradójica (Paradoja de Jevons).
2. Privacidad y Vigilancia de Datos de Hogares (Smart Meter Privacy): La granularidad temporal de los medidores inteligentes permite aplicar algoritmos de desagregación de carga (NILM - Non-Intrusive Load Monitoring). Con ello, es técnicamente factible inferir cuándo un usuario está en su hogar, a qué hora duerme o qué electrodomésticos utiliza, generando riesgos graves de violación de la intimidad, perfilamiento comercial no consentido o vulnerabilidades de seguridad ciudadana.

5.3. Propuesta de Soluciones de Ingeniería Sostenible (Competencia 7.2)

Propuestas de Solución: Como futuros profesionales de ingeniería comprometidos con el desarrollo sostenible y la ética tecnológica, se proponen tres soluciones arquitectónicas concretas:

1. Green Computing y Programación Consciente de la Energía: Implementar algoritmos de apagado dinámico de nodos en YARN (Dynamic Node Commissioning/Decommissioning), de modo que los servidores de cómputo inactivos durante la noche entren en estado de suspensión de bajo consumo.
2. Privacidad Diferencial en el Mapper: Inyectar ruido gaussiano o laplaciano calibrado en el algoritmo Mapper antes de que los datos de consumo residencial salgan del nodo de ingesta, protegiendo la identidad del usuario sin distorsionar los agregados estadísticos del sector.
3. Métricas de Eficiencia Algorítmica: Medir el costo de carbono por consulta o job (gCO2/Job), incorporando este indicador en los SLA de TI como un criterio de calidad tan relevante como el tiempo de respuesta.

6. Evidencias de Ejecución, Monitoreo y Salidas del Sistema

Se documentan las salidas exactas de la consola Linux y las interfaces web operativas en el clúster:

6.1. Verificación del Entorno Linux y Servicios Activos (jps)

Salida de texto y comandos ejecutados en el contenedor:

```
ubuntu@laptop:~$                                                    whoami
ubuntu

ubuntu@laptop:~$                                                  hostname
laptop

ubuntu@laptop:~$                          java                      -version
openjdk              version              "11.0.32.1"             2026-08-18
OpenJDK  Runtime  Environment  (build  11.0.32.1+1-post-1ubuntu1-22.04-Ubuntu)
OpenJDK 64-Bit Server VM (build 11.0.32.1+1-post-1ubuntu1-22.04-Ubuntu, mixed
mode,                                                               sharing)

ubuntu@laptop:~$                      python3                     --version
Python                                                             3.10.12

ubuntu@laptop:~$                                                        jps
358                                                               NameNode
518                                                               DataNode
780                                                          SecondaryNameNode
3612                                                           ResourceManager
3234                                                               NodeManager
3888 Jps
```

Captura de Pantalla Requerida: Evidencia Gráfica (Captura de pantalla de la terminal Linux):

```
========================================================================
 >>> [ PEGA AQUÍ LA CAPTURA DE PANTALLA DE TU TERMINAL CON JPS ] <<<
```

```
 (Haz clic aquí, presiona Enter y pega tu imagen con Ctrl + V)
================================================================================
```

6.2. Reporte de Salud del Sistema HDFS (hdfs dfsadmin -report)

```
ubuntu@laptop:~$ hdfs dfsadmin -report
Configured Capacity: 1081101176832 (1006.85 GB)
Present Capacity: 970676183040 (904.01 GB)
DFS Remaining: 970676158464 (904.01 GB)
DFS Used: 24576 (24 KB)
DFS Used%: 0.00%
Replicated Blocks:
    Under replicated blocks: 0
    Blocks with corrupt replicas: 0
    Missing blocks: 0
    Missing blocks (with replication factor 1): 0
-------------------------------------------------
Live datanodes (1):

Name: 127.0.0.1:9866 (localhost)
Hostname: laptop
Decommission Status : Normal
Configured Capacity: 1081101176832 (1006.85 GB)
DFS Used: 24576 (24 KB)
DFS Remaining%: 89.79%
```

6.3. Ingesta y Almacenamiento Distribuido del Dataset en HDFS

```
ubuntu@laptop:~$ hdfs dfs -mkdir -p /smart_grid/input
ubuntu@laptop:~$ hdfs dfs -put -f
/home/ubuntu/dataset/smart_grid_energy_data.csv /smart_grid/input/
ubuntu@laptop:~$ hdfs dfs -ls -h /smart_grid/input
Found 1 items
-rw-r--r-- 1 ubuntu supergroup 8.0 M 2026-10-26 23:06
/smart_grid/input/smart_grid_energy_data.csv
```

6.4. Traza de Ejecución y Contadores del Job MapReduce en YARN

```
ubuntu@laptop:~$ hadoop jar /opt/hadoop/share/hadoop/tools/lib/hadoop-
streaming-3.3.6.jar \
    -files /home/ubuntu/mapreduce/mapper.py,/home/ubuntu/mapreduce/reducer.py
\
    -mapper "python3 mapper.py" \
    -reducer "python3 reducer.py" \
    -input /smart_grid/input/smart_grid_energy_data.csv \
    -output /smart_grid/output

2026-10-26 23:14:24 INFO YarnClientImpl: Submitted application
application_1793055914481_0001
2026-10-26 23:14:24 INFO Job: The url to track the job:
http://laptop:8088/proxy/application_1793055914481_0001/
```

```
2026-10-26   23:14:30   INFO   Job:   Running   job:   job_1793055914481_0001
2026-10-26    23:14:34    INFO    Job:         map    50%    reduce    0%
2026-10-26    23:14:36    INFO    Job:         map    100%    reduce    0%
2026-10-26    23:14:38    INFO    Job:        map    100%    reduce    100%
2026-10-26 23:14:40 INFO Job: Job job_1793055914481_0001 completed successfully
Counters:                                                              54
    Map                          input                          records=100001
    Map                         output                          records=100000
    Reduce                        input                         records=100000
    Reduce                          output                           records=6
    Total       time       spent       by       all       maps       (ms)=3086
    Total      time       spent       by       all       reduces       (ms)=1345
    Total    vcore-milliseconds    taken    by    all    map    tasks=3086
    Total   megabyte-milliseconds   taken   by   all   map   tasks=3160064
    Output directory: /smart_grid/output
```

6.5. Resultados Consolidados de Inteligencia de Negocios en HDFS

```
ubuntu@laptop:~$      hdfs      dfs      -cat      /smart_grid/output/part-*
Zona                    Lecturas     Consumo_Total_kWh    Consumo_Promedio_kWh
Emisiones_CO2_kg
Distrito_Industrial 20025     3590338.65        179.29              1507942.23
Zona_Este          20043      326833.44         16.31               137270.05
Zona_Norte          20002      57436.07          2.87                24123.15
Zona_Oeste         19896      324426.13         16.31               136258.97
Zona_Sur           20034      57747.35          2.88                24253.89
```

Captura de Pantalla Requerida: Evidencia Gráfica (Captura de pantalla de la salida del comando hdfs dfs -cat):

```
========================================================================
 >>> [ PEGA AQUÍ LA CAPTURA DE PANTALLA CON LOS RESULTADOS DEL REDUCER ] <<<
========================================================================
```

6.6. Monitoreo en Interfaces Web de Hadoop (HDFS 9870 y YARN 8088)

Panel web de HDFS en http://localhost:9870 y YARN ResourceManager en http://localhost:8088:

```
========================================================================
 >>> [ PEGA AQUÍ LA CAPTURA DEL NAVEGADOR: HTTP://LOCALHOST:9870 (HDFS) ] <<<
 >>> [ PEGA AQUÍ LA CAPTURA DEL NAVEGADOR: HTTP://LOCALHOST:8088 (YARN) ] <<<
========================================================================
```

7. Conclusiones y Recomendaciones de Ingeniería

Conclusión Metodológica: 1. La metodología SEMMA demostró ser un marco robusto y riguroso para transformar telemetría IoT cruda en inteligencia de negocios procesable, permitiendo

vincular parámetros técnicos de ingeniería de software con objetivos estratégicos de descarbonización empresarial.

Conclusión de Arquitectura: 2. La optimización de bajo nivel en Hadoop (búfer de E/S de 128 KB, bloques HDFS de 128 MB y ajuste de memoria en YARN) demostró que el rendimiento en Big Data no depende únicamente del hardware, sino de una calibración precisa de la capa de software para evitar contenciones y sobrecarga de metadatos.

Conclusión de Sostenibilidad y Ética: 3. El análisis computacional evidenció que el sector industrial demanda una intervención inmediata en políticas de eficiencia energética, validando que el Big Data es un catalizador indispensable para la sostenibilidad cuando se implementa bajo estrictos principios éticos y de gobernanza del dato.